

Modèle CLIP ARN–protéine et niches spatiales multi-omiques

Méthodologie, résultats et analyses — rapport détaillé

Louise Lapie — CDD (6 mois)

Juin 2026 (document de travail pour la présentation du 9 juillet 2026)

Abstract

Ce rapport documente un modèle contrastif (CLIP) alignant, pour des cellules *strictement appariées*, une vue **transcriptomique** (ARN) et une vue **protéomique** (protéine), sur deux jeux de données de transcriptomique spatiale sub-cellulaire : **CosMx** (sein, 64 marqueurs protéiques) et **Xenium** (rein, 27 marqueurs). À partir des embeddings cellulaires du modèle, on calcule des **niches spatiales** en réutilisant la « fin de NOVAE » (projection sur la sphère, prototypes, transport optimal, clustering hiérarchique). On compare plusieurs encodeurs ARN (NOVAE *vs* scConcept) et plusieurs espaces (ARN seul, protéine seule, multi-omique) selon : la continuité spatiale (FIDE), le recouvrement avec les types cellulaires, une analyse d'*information* (variance expliquée), et surtout une **validation contre des annotations de pathologie** (vérité terrain, Xenium). Le message principal : **NOVAE produit de vraies niches spatiales** là où scConcept produit surtout du typage cellulaire ; et **l'intégration multi-omique apporte un signal protéique réel**, retrouvant mieux l'histologie que chaque modalité prise seule. L'avantage reste toutefois **compétitif plutôt que décisif** une fois la baseline ARN fortement entraînée (NOVAE fine-tuné), ce qui motive les expériences à venir.

Contents

1	Contexte et objectif	1
2	Données	1
3	Méthodologie	2
3.1	Modèle CLIP ARN–protéine	2
3.2	Tête de niches : la « fin de NOVAE »	2
3.3	Espaces d'embeddings comparés	2
3.4	Métriques d'évaluation	3
3.5	Analyse d'information (variance expliquée)	3
3.6	Validation pathologie (Xenium)	3
3.7	Baselines et benchmark	3
4	Résultats	3
4.1	Retrieval cross-modal (contexte)	4
4.2	Qualité spatiale des niches (FIDE)	4
4.3	NOVAE vs scConcept (niches multi-omiques)	4
4.4	Information : multi- vs uni-omique	4
4.5	Validation pathologie (Xenium) — le résultat clé	4
4.6	Robustesse au nombre de domaines	4
4.7	Les niches valent-elles mieux que du typage ?	4
4.8	Benchmark vs méthodes de référence (Xenium, $n=5$)	5

5	Analyse et discussion	5
6	Limites (à dire honnêtement)	6
7	Conclusion et perspectives	6
A	Structure du code (dépôt CLIP_baseline)	7

1 Contexte et objectif

La transcriptomique spatiale conserve la position des cellules, ce qui permet d'étudier les *micro-environnements* (ou **niches** / domaines spatiaux). Le projet vise à entraîner un premier modèle **CLIP-like** qui apprend un espace commun entre l'ARN et la protéine de cellules appariées, puis à se demander :

1. l'embedding *multi-omique* produit-il de *meilleures niches* que chaque modalité seule ?
2. quel encodeur ARN gelé vaut-il mieux donner au CLIP : **NOVAE** (conscient du voisinage spatial) ou **scConcept** (par cellule) ?

Un constat de départ oriente toute l'étude : au *retrieval* cross-modal (retrouver la protéine d'une cellule à partir de son ARN), **scConcept bat NOVAE** (R@5 moyen sur CosMx : $\approx 2,6\%$ pour scConcept contre $\approx 0,7\%$ pour NOVAE). Le retrieval est une métrique *cellule-à-cellule*. La question devient alors : est-ce que cet avantage s'inverse au niveau *voisinage*, c'est-à-dire pour les niches ?

2 Données

Jeu	Tissu	Cellules	Gènes (ARN)	Marqueurs prot.	Annotations
CosMx	sein	152 446	$\sim 20\,000$	64	types cellulaires
Xenium	rein	465 498	405	27	types cellulaires + pathologie

Table 1: Les deux jeux de données. Chaque cellule possède une vue ARN *et* une vue protéine (même cellule). Coordonnées spatiales (μm) disponibles. Le Xenium dispose en plus d'**annotations de pathologie** (régions tracées par un pathologiste sur le H&E, alignées sur les cellules).

Splits. Un découpage spatial train/val/test/buffer existe pour l'entraînement supervisé du CLIP (le *retrieval* s'évalue sur le test tenu à l'écart). La découverte de niches étant *non supervisée*, elle utilise la lame entière (aucune fuite d'étiquette).

3 Méthodologie

3.1 Modèle CLIP ARN-protéine

Deux « tours » projettent chaque modalité dans un espace commun de dimension 256, normalisé L2 :

- **Tour ARN** : embedding gelé (NOVAE 64d *ou* scConcept 512d, précalculé) $\rightarrow$ Linear $\rightarrow$ L2 = z_r .
- **Tour protéine** : intensités prétraitées (clip 1–99, $\log(1+x)$, z-score par marqueur, ajusté sur le train) $\rightarrow$ MLP $\rightarrow$ L2 = z_p .

Loss **InfoNCE symétrique** (température 0,07) : la paire positive de la ligne i est la colonne i . On obtient, par cellule, z_r et z_p , et la **fusion multi-omique** $z_{\text{joint}} = \text{L2}(z_r + z_p)$.

3.2 Tête de niches : la « fin de NOVAE »

On réutilise la partie inférence (zero-shot) de NOVAE¹ appliquée à des embeddings *quelconques* (module `src/niches.py`) :

1. projection sur la **sphère unité** (L2) ;
2. **prototypes** = $K=512$ centres de KMeans sur les embeddings normalisés ;
3. **attribution** d'un prototype « feuille » par cellule (argmax cosinus ; variante transport optimal / Sinkhorn disponible) ;
4. **clustering hiérarchique** (cosine, average) des prototypes $\rightarrow$ arbre coupé à `n_domains` domaines (= niches).

Nuance importante : le transport optimal sert dans NOVAE à l'**entraînement** (cible de la loss SwAV) ; à l'**inférence**, l'attribution se fait par argmax cosinus. Les embeddings du CLIP étant déjà L2-normalisés, l'étape « sphère » est neutre pour eux ; ce que NOVAE *ajoute* réellement, c'est la machinerie prototypes $\rightarrow$ hiérarchie, pas la normalisation.

3.3 Espaces d'embeddings comparés

<code>novae_raw</code>	embedding NOVAE gelé (64d) — <i>ARN seul</i> , $\approx$ <i>NOVAE zero-shot</i>
<code>clip_rna</code>	z_r (256d) — vue ARN projetée par le CLIP
<code>clip_prot</code>	z_p (256d) — vue protéine projetée par le CLIP
<code>clip_joint</code>	$L2(z_r + z_p)$ (256d) — multi-omique
<code>scconcept_*</code>	idem mais encodeur ARN scConcept (512d)

Tous les espaces sont évalués sur le **même graphe spatial** (kNN, $k=6$) pour une comparaison équitable.

3.4 Métriques d'évaluation

FIDE F1 des arêtes intra-domaine. *Haut* = niches spatialement continues (gros blocs contigus, pas du « sel-et-poivre »). *Mesure la continuité, pas la justesse biologique.*

Entropie normalisée équilibre des tailles de niches.

Heuristique = FIDE $\times$ entropie (compromis ; c'est le critère de réglage d'hyperparamètres de NOVAE).

ARI / NMI vs types recouvrement des niches avec les types cellulaires. *Bas* = niche $\neq$ type (sain : une niche est un voisinage, pas un type).

ARI / NMI / homogénéité vs pathologie accord avec les régions du pathologiste (vérité terrain externe, Xenium). *C'est la métrique la plus objective.*

ARI vs NMI. L'ARI raisonne sur les *paires* de cellules et pénalise fort les différences de granularité ; le NMI est informationnel et tolère mieux qu'une partition soit plus fine que l'autre. On rapporte les deux.

3.5 Analyse d'information (variance expliquée)

Pour tester si une partition « contient de l'information » sur une modalité, on mesure la **variance expliquée** (η^2) : $EV = 1 - SS_{\text{intra}}/SS_{\text{total}}$. Haut = les cellules d'une même niche se ressemblent dans cette modalité. Cible protéine = intensités brutes ; cible ARN = **comptages bruts** (indépendants), pour éviter la circularité (la jointe contient déjà l'ARN NOVAE). Un test de **permutation** (drill-down) vérifie que les sous-divisions d'une niche ARN par la jointe correspondent à de *vraies* différences de protéine.

¹Blampey *et al.*, *Novae: a graph-based foundation model for spatial transcriptomics data*, Nature Methods 22:2539–2550 (2025).

3.6 Validation pathologie (Xenium)

Le pathologiste a tracé 9 régions sur le H&E (Tumor×3, Necrosis, Immune cells, Immune infiltration, Hemorrhage, Adipose, Blood vessels), exportées en GeoJSON. Une matrice affine 3×3 (*image alignment*) ramène ces polygones dans le repère μm des cellules ; on assigne chaque cellule à sa région (point-dans-polygone). Le bon sens de la transformation a été déterminé *empiriquement* puis confirmé biologiquement (**Tumor**→32 % malignes, **Immune cells**→33 % T + 17 % B). 92 % des cellules tombent dans une région annotée.

3.7 Baselines et benchmark

Pour situer le multi-omique face à des méthodes de domaines spatiaux (module **benchmark/**) :

- **NOVAE zero-shot** (=novae_raw) et **NOVAE fine-tuné** (ré-entraîné quelques epochs sur la lame, auto-supervisé) — ARN seul ;
- **BANKSY-style** (propre + moyenne du voisinage, λ -pondéré, KMeans) — sur ARN *et* sur protéine ;
- **Cellular Neighborhoods** (Schürch 2020 : phénotypes protéiques → composition du voisinage → KMeans) — niche *protéique dédiée*.

Note d'honnêteté : BANKSY-style et CN sont des versions simplifiées (sans le filtre de Gabor azimutal de BANKSY officiel) ; suffisantes pour une première idée, à remplacer par les packages officiels pour publication.

4 Résultats

Avertissement de cohérence : suite aux ré-exécutions, les niches CosMx sont rapportées à $n_{\text{dom}}=10$ et les niches Xenium à $n_{\text{dom}}=5$; le **n_domains** est précisé dans chaque table. Le balayage de la section 4.6 couvre $n \in \{5, 7, 10, 15\}$.

4.1 Retrieval cross-modal (contexte)

Sur le test, le CLIP **scConcept** bat le CLIP **NOVAE** (R@5 moyen CosMx $\approx 2,6\%$ vs $0,7\%$). Les valeurs absolues sont faibles (tâche difficile, galerie immense), mais le *classement* est net : au niveau cellulaire, scConcept porte plus de signal fin corrélé à la protéine. C'est le point de départ : voyons les niches.

4.2 Qualité spatiale des niches (FIDE)

Jeu (n)	espace	FIDE	entropie	heuristique	NMI/types
CosMx (10)	novae_raw	0.599	0.922	0.552	—
	clip_rna	0.649	0.922	0.598	—
	clip_prot	0.689	0.846	0.583	—
	clip_joint	0.739	0.846	0.625	—
Xenium (5)	novae_raw	0.815	0.627	0.511	0.135
	clip_rna	0.851	0.636	0.541	0.140
	clip_prot	0.608	0.858	0.521	0.268
	clip_joint	0.792	0.811	0.642	0.182

Table 2: FIDE des quatre espaces. **CosMx** (protéine riche, 64 marqueurs) : **clip_joint** est le meilleur en FIDE *et* en heuristique. **Xenium** (protéine mince, 27 marqueurs) : **clip_prot** est faible (0.608) et tire la fusion vers le bas (FIDE **clip_joint** 0.792 < **clip_rna** 0.851) — bien que **clip_joint** reste le meilleur en *heuristique* (0.642) grâce à des niches plus équilibrées. **Le bénéfice du multi-omique dépend de la richesse du panel protéique.**

4.3 NOVAE vs scConcept (niches multi-omiques)

Jeu (n)	modèle	FIDE	heuristique	ARI/types	NMI/types
CosMx (10)	NOVAE	0.739	0.625	0.008	0.079
	scConcept	0.503	0.476	0.033	0.145
Xenium (5)	NOVAE	0.792	0.642	0.112	0.182
	scConcept	0.498	0.462	0.409	0.508

Table 3: Niches multi-omiques (clip_joint) : **NOVAE bat nettement scConcept** en continuité spatiale (FIDE) sur les deux tissus. Surtout, sur Xenium le NMI/types de scConcept atteint **0.508** : ses « niches » sont presque une *carte de types cellulaires*, alors que NOVAE reste à 0.182 (niches distinctes des types). **NOVAE fait des niches ; scConcept fait du typage.**

4.4 Information : multi- vs uni-omique




Figure 1: Variance expliquée (cibles indépendantes). À *gauche* : la niche jointe explique la protéine mieux que la niche ARN (+0.080 CosMx, +0.044 Xenium) → elle **intègre du protéique**. À *droite* : l'axe ARN-comptages est près du plancher pour *toutes* les partitions (même *niche_ARN*) — une niche grossière ne peut pas résumer le transcriptome cellule-à-cellule, dominé par le bruit (dropout). Ce n'est pas une absence d'information ARN, c'est une inadéquation d'échelle.

Le **drill-down** confirme : une niche ARN scindée par la jointe donne des sous-niches aux profils protéiques *réellement* distincts (test de permutation $p \approx 0,005$ sur les deux tissus). **Conclusion : la protéine ajoute une information réelle, plus marquée quand le panel est riche (CosMx).**

4.5 Validation pathologie (Xenium) — le résultat clé

méthode (clip_joint, $n=10$)	ARI	NMI	homogénéité
NOVAE_joint (multi-omique)	0.206	0.287	0.539
NOVAE_raw (ARN seul)	0.112	0.187	0.348
scConcept_joint	0.064	0.138	0.291

Table 4: Accord avec la pathologie (vérité terrain). Le multi-omique NOVAE retrouve le mieux les régions du pathologiste, $\approx 2\times$ l'ARN seul, scConcept dernier. **Important :** ce résultat *nuance* le FIDE (où la fusion semblait nuire sur Xenium) — contre la vraie histologie, le multi-omique gagne.




Figure 2: Cartes spatiales ($n=5$), même code couleur (niche colorée par sa région dominante). De gauche à droite : **pathologie** (vérité terrain), **NOVAE_joint** (multi-omique), **NOVAE_raw** (ARN seul). Le multi-omique retrouve mieux les zones immunitaires (bleu).




Figure 3: Correspondance niche $\rightarrow$ région (NOVAE_joint, % des cellules de chaque niche). Les niches 0/3/6/7 $\approx$ Tumor, 2/5/8 $\approx$ Immune ; les niches sont plus *fin*es que les régions (plusieurs niches se partagent la tumeur), ce qui plafonne l'ARI.

4.6 Robustesse au nombre de domaines

ARI vs pathologie	$n=5$	$n=7$	$n=10$	$n=15$
NOVAE_joint	0.426	0.414	0.206	0.134
NOVAE_raw	0.193	0.167	0.112	0.139
scConcept_joint	0.044	0.045	0.064	0.063

Table 5: Balayage de n_{dom} . NOVAE_joint domine à $n=5, 7, 10$ (et l'accord *absolu* est le meilleur à $n \approx 5$, qui correspond au nombre de régions annotées). À $n=15$ l'avantage s'efface (sur-découpage vs ~ 5 régions grossières). **Fenêtre à rapporter** : $n=5-10$. Choisir n pour *maximiser* l'accord serait un biais ; ici on rapporte tous les n (comme l'article NOVAE, qui benchmarke à 7/10/15).

4.7 Les niches valent-elles mieux que du typage ?

Baseline « types cellulaires seuls » vs pathologie : ARI 0.05–0.09 (cell_type_final 0.051 / 0.077 ; qc_celltype_cpu 0.088 / 0.094) — très en dessous des niches (NOVAE_joint 0.206). **Les niches capturent une vraie structure spatiale, pas un recoloriage des types.**




Figure 4: ARI et NMI vs pathologie en fonction de n_{dom} pour les trois méthodes.

méthode	modalité	ARI	NMI	homog.
NOVAE_joint	multi-omique	0.426	0.341	0.487
NOVAE fine-tuné	ARN	0.239	0.353	0.552
BANKSY-style	ARN	0.193	0.278	0.436
NOVAE zero-shot (novae_raw)	ARN	0.193	0.157	0.198
Cellular Neighborhoods	protéine	0.182	0.251	0.396
BANKSY-style	protéine	0.135	0.235	0.368
scConcept_joint	multi-omique	0.044	0.119	0.192

Table 6: Multi-omique vs baselines uni-modales et NOVAE fine-tuné. **(i)** Le multi-omique bat *chaque modalité seule* : ARN (≤ 0.19) et protéine (≤ 0.18) — y compris une méthode protéique *dédiée* (CN). **(ii)** Mais face au **NOVAE fine-tuné** (baseline ARN forte), la comparaison se resserre : le multi-omique gagne sur l’ARI (0.426 vs 0.239) mais le fine-tuné *égale/dépasse* sur le NMI (0.353 vs 0.341) et l’homogénéité. **Avantage réel mais pas décisif** une fois l’ARN bien entraîné.

4.8 Benchmark vs méthodes de référence (Xenium, $n=5$)

5 Analyse et discussion

- NOVAE = niches, scConcept = typage (solide).** Sur les deux tissus, NOVAE donne des niches spatialement continues et distinctes des types ; scConcept donne des cartes qui collent aux types cellulaires (NMI/types jusqu’à 0.51 sur Xenium). Pour une tâche de domaines spatiaux, un encodeur conscient du voisinage est le bon choix — *même s’il perd au retrieval cellulaire*. C’est la dissociation centrale : retrieval (cellule) et niche (voisinage) mesurent des choses différentes.
- Le multi-omique apporte un signal protéique réel.** Validé par l’analyse d’information ($p \approx 0.005$) *et* par la pathologie : le multi-omique retrouve l’histologie mieux que l’ARN seul, la protéine seule, et même une méthode protéique dédiée.
- Mais l’avantage dépend du panel et de la baseline.** Le bénéfice FIDE n’apparaît que si la protéine est riche (CosMx) ; et face à un NOVAE *fine-tuné* l’écart se resserre (métrique-dépendant). On ne peut donc pas écrire « multi-omique » ARN » sans nuance.
- FIDE $\neq$ information $\neq$ pathologie.** Trois angles complémentaires : FIDE (continuité, gameable par le déséquilibre), information (apport protéine réel), pathologie (justesse biologique, vérité terrain). Ils convergent sur le message principal mais éclairent des aspects différents.

6 Limites (à dire honnêtement)

- **Une seule slide par tissu, une seule seed** : robustesse statistique limitée.
- **Vérité terrain grossière** : ~ 5 régions, dominées par la tumeur (77 %), tracées à la main → plafonne l'ARI, valide les *grands compartiments* pas les niches fines.
- **Baselines simplifiées** (BANKSY/CN sans toutes leurs options ; pas encore STAGATE/GraphST/BANKS officiel).
- **Confusion méthode/modalité** : NOVAE_joint (CLIP) vs NOVAE fine-tuné mélange architecture *et* modalité. Le contrôle « même méthode sur ARN / protéine / ARN+protéine » reste à faire pour isoler proprement l'apport protéine.
- **Validation sur toutes les cellules** : pour être imparable, ré-évaluer sur les cellules *test* uniquement.

7 Conclusion et perspectives

Conclusion. En réutilisant la tête de niches de NOVAE sur les embeddings d'un CLIP ARN-protéine, on obtient des niches multi-omiques qui (i) sont spatialement cohérentes, (ii) intègrent un signal protéique réel, et (iii) retrouvent l'histologie annotée mieux que chaque modalité seule. NOVAE s'impose pour les niches là où scConcept fait du typage. L'avantage multi-omique est *réel et prometteur, mais pas encore décisif* face à une baseline ARN fortement entraînée.

Perspectives (prochaines étapes).

1. **NOVAE fine-tuné en entrée du CLIP** : refaire le CLIP sur des embeddings ARN fine-tunés pour la comparaison équitable au niveau fine-tuné (`benchmark/precompute_novae_finetuned.py` prêt).
2. **Contrôle « même méthode »** (ARN / protéine / ARN+protéine) pour isoler l'apport protéine sans confondre architecture et modalité.
3. **Benchmark officiel** : BANKSY, STAGATE, GraphST ; **plus de slides** (et JSD inter-slides) ; idéalement une **trouvaille biologique**.
4. **Évaluation sur le test** uniquement, et **plusieurs seeds**.

A Structure du code (dépôt CLIP_baseline)

<code>src/model.py</code>	modèle CLIP (tours ARN/protéine, InfoNCE)
<code>src/niches.py</code>	tête de niches « fin de NOVAE » (sphère, prototypes, hiérarchie)
<code>src/eval_niches.py</code>	calcul des niches + FIDE/entropie/heuristique/JSD/ARI-NMI
<code>src/compare_niches.py</code>	comparaison inter-runs (NOVAE vs scConcept)
<code>src/niche_information.py</code>	variance expliquée + plan d'information + drill-down
<code>src/pathology_validation.py</code>	GeoJSON + alignement → accord vs pathologie
<code>tools/scan_ndomains.sh</code>	balayage de n_{dom} + courbe ARI/NMI
<code>tools/make_niche_recap.py</code>	figures récap
<code>benchmark/run_banksy.py</code>	baseline BANKSY-style (ARN ou protéine)
<code>benchmark/run_cellular_neighborhoods.py</code>	niche protéique dédiée (Schürch)
<code>benchmark/run_novae_finetune.py</code>	NOVAE fine-tuné (domaines)
<code>benchmark/precompute_novae_finetuned.py</code>	embeddings ARN fine-tunés (pour re-CLIP)
